Rodrigo Baptista de Barros

12562010

rodrigobapbarros@usp.br

PCS5787-4: Ciência dos Dados e Big Data

Atividade 4:

1 Exercício

Enunciado: Considere que um algoritmo qualquer, gerou um classificador que identifica se o preço da soja é referente a colheita ou plantio. O algoritmo utilizou somente os valores dos atributos ano e preço para gerar as seguintes regras:

- Caso ano seja 2014 e o preço seja maior ou igual a R$ 67,00, então é período de "Colheita"
- Caso ano seja 2015) e o preço esteja igual ou entre R$58,00 e R$62,00, então é período é Colheita
- Caso não seja nenhuma das duas situações, é período de Plantio.

Sabe-se que, em contrapartida, o período de colheita da soja ocorre entre os meses de janeiro a maio de cada ano (de 01/01 a 31/05).

Baseado nessas informações, resolva os seguintes exercícios:

- Selecione uma amostra para testes, utilizando uma técnica adequada;
- Construa a Matriz Confusão e calcule: Acurácia, Precisão, Revocação e Especificidade;
- Gere o gráfico ROC do Algoritmo Classificador de Colheita da Soja e analise o desempenho preditivo do Algoritmo.

2 Solução

Para a realização do exercício, foi primeiro realizada a criação do modelo, com base nas condições ditas. Apesar disso, vale ressaltar que estas condições nos dão um resultado "binário", somente com "Colheita" e "Plantio. Foram criadas, ao final do dataset inicial "base", as colunas "Estágio Previsto" e "Estágio Real".

Após este estágio, por meio do uso da biblioteca *train_test_split"*, foi realizada a separação das amostras em 0.25 para teste e 0.75 para treinamento. Além disso, para garantir a reprodutibilidade e remover vieses, foi realizada a inserção dos parâmetros *random_state = 1* e *stratify=soja_real*, este último garantindo proporção entre dados de colheita e plantio.

[24]:
```
condicoes_predicted1 = (base["Ano - Safra"] == 2014) & (base["Preços - Soja"] >= 67.00)
condicoes_predicted2 = (base["Ano - Safra"] == 2015) & (base["Preços - Soja"] >= 58.00) & (base["Preços - Soja"] <= 62.00)
```

[25]:
```
base_predicted["Estágio"] = np.where(condicoes_predicted1|condicoes_predicted2, "Colheita", "Plantio")
```

[26]:
```
base_predicted
```

[26]:

	Observação	Data	Mês	Ano - Safra	Preços - Milho	Preços - Soja	Estágio
0	1	02/01/2014	1	2014	26.64	72.18	Colheita
1	2	03/01/2014	1	2014	27.00	71.42	Colheita
2	3	06/01/2014	1	2014	27.29	71.38	Colheita
3	4	07/01/2014	1	2014	27.49	70.31	Colheita
4	5	08/01/2014	1	2014	27.16	70.14	Colheita
...	...	...	...	...	...	...	...
493	494	22/12/2015	12	2015	36.23	78.61	Plantio
494	495	23/12/2015	12	2015	36.26	78.21	Plantio
495	496	28/12/2015	12	2015	36.29	77.59	Plantio
496	497	29/12/2015	12	2015	36.55	78.55	Plantio
497	498	30/12/2015	12	2015	36.83	78.07	Plantio

498 rows × 7 columns

[27]:
```
condicoes_real = (base["Mês"] <= 5)
```

[28]:
```
base_real["Estágio"] = np.where(condicoes_real, "Colheita", "Plantio")
```

[42]:
```
soja_treino
```

[42]:

	Observação	Data	Mês	Ano - Safra	Preços - Milho	Preços - Soja	Estágio Previsto	Estágio Real
104	105	04/06/2014	6	2014	27.33	69.30	Colheita	Plantio
28	29	11/02/2014	2	2014	28.93	65.52	Plantio	Colheita
477	478	30/11/2015	11	2015	33.25	76.65	Plantio	Plantio
136	137	22/07/2014	7	2014	22.99	61.83	Plantio	Plantio
332	333	05/05/2015	5	2015	25.82	63.70	Plantio	Colheita
...	...	...	...	...	...	...	...	...
31	32	14/02/2014	2	2014	30.11	67.76	Colheita	Colheita
127	128	08/07/2014	7	2014	24.48	64.84	Plantio	Plantio
407	408	19/08/2015	8	2015	27.34	70.96	Plantio	Plantio
399	400	07/08/2015	8	2015	27.60	73.18	Plantio	Plantio
398	399	06/08/2015	8	2015	27.08	73.09	Plantio	Plantio

373 rows × 8 columns

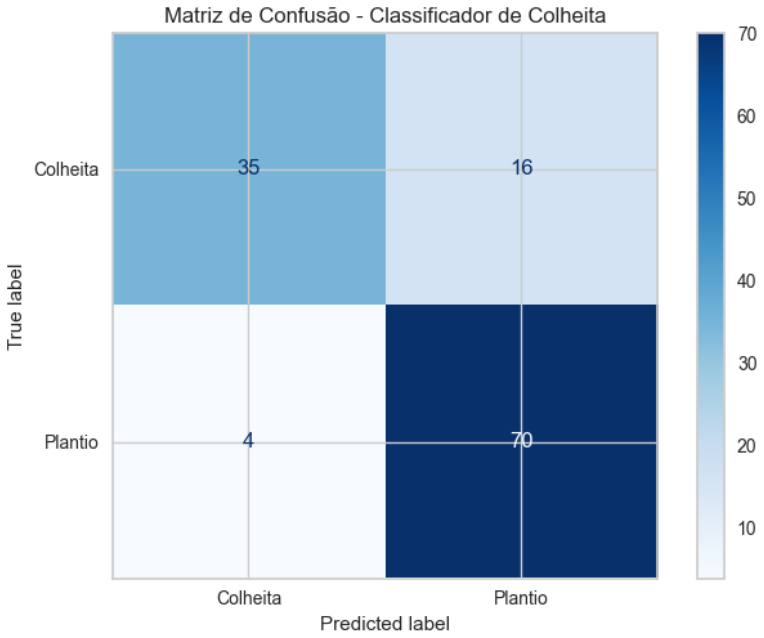
[43]:
```
soja_teste
```

[43]:

	Observação	Data	Mês	Ano - Safra	Preços - Milho	Preços - Soja	Estágio Previsto	Estágio Real
118	119	25/06/2014	6	2014	25.48	67.02	Colheita	Plantio
50	51	17/03/2014	3	2014	33.37	68.50	Colheita	Colheita
495	496	28/12/2015	12	2015	36.29	77.59	Plantio	Plantio
8	9	14/01/2014	1	2014	27.35	67.78	Colheita	Colheita
188	189	02/10/2014	10	2014	21.91	58.75	Plantio	Plantio
...	...	...	...	...	...	...	...	...
443	444	09/10/2015	10	2015	32.36	76.00	Plantio	Plantio
361	362	16/06/2015	6	2015	25.16	62.21	Plantio	Plantio
282	283	19/02/2015	2	2015	28.18	61.42	Colheita	Colheita
111	112	13/06/2014	6	2014	26.42	66.84	Plantio	Plantio
454	455	27/10/2015	10	2015	33.04	78.39	Plantio	Plantio

125 rows × 8 columns

À partir destes dados, foi realizada a matriz de confusão, por meio da biblioteca ”sklearn.metrics”.



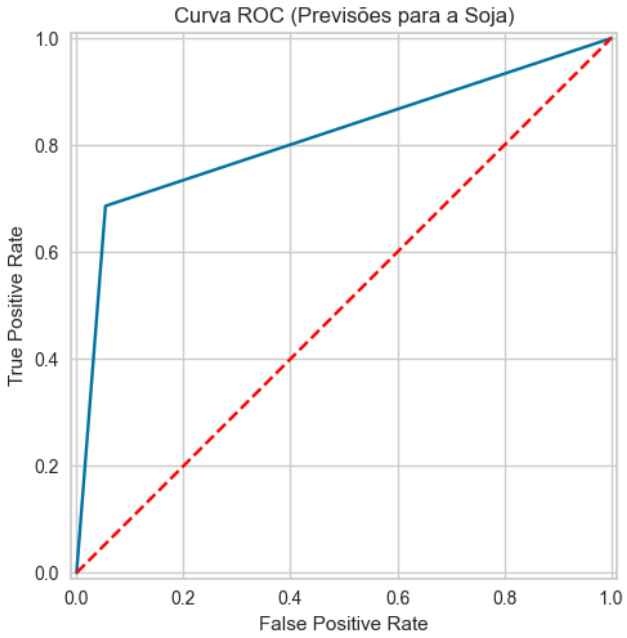
Assim, temos que

- VP: 35
- FP: 4
- FN: 16
- VN: 70

À partir disso, foi calculado:

- Acurácia: 0.84
- Precisão: 0.897
- Revocação: 0.686
- Especificidade: 0.946

Para a realização da curva ROC, foi realizado o encoding dos dados para forma binária numérica. Após isso, foi realizado o plot da curva.



Assim, temos que

- AUC: 0.81

Há diversas métricas para analisar o desempenho preditivo do algoritmo.

Considerando que o modelo atingiu 84% de acertos entre todas as classificações efetuadas, pode-se assumir que tende a acertar grande parte das previsões, prevendo inclusive com alta taxa de acerto a colheita (90%). A revocação, em contrapartida, é um fator a ser explicitado. De todas as colheitas reais, o modelo deixou de capturar mais de 30%, tendo somente 68,6% das colheitas previstas. Isto pode causar, em uma situação ideal, uma grande perda com relação à mercadoria. Já escassez não tende a ocorrer, pois o modelo obteve grande especificidade, com 94.6% de identificação nos períodos de plantio. O AUC apresentou um bom valor, o que indicaria um alto desempenho do modelo na previsão de medidas.

Em geral, pela simplicidade do modelo, pode-se dizer que apresentou bons resultados. De qualquer modo, não deve ser utilizado como parâmetro para previsão, dada a simplicidade do modelo e limites conhecidos temporais (01 até 05) como momentos de colheita. Apesar disso, é um bom começo para a criação de um modelo de predição.

O código python está disponível em anexo nesta atividade